

Integrasi Rule-Based Filtering dan Stacking Ensemble untuk Deteksi Website Phishing

Sarah Rosdiana¹⁾, Nikita Simanjuntak²⁾, Grace Arintya Siahaan³⁾,
Ruben Martogi Jeremia Sianipar⁴⁾

Jurusan Sistem Informasi, Fakultas Informatika dan Teknik Elektro,
Institut Teknologi Del, Jl Sisingamangaraja Laguboti
Toba, Sumatera Utara 22381, Indonesia
Email : sarah.tambunan@del.ac.id

Riwayat Artikel

Diterima:
01-01-2024

Direvisi:
01-02-2024

Disetujui:
01-03-2024

Abstract

Phishing attacks targeting financial and banking sectors continue to increase, requiring detection systems that are not only accurate but also efficient and interpretable. Existing approaches rely predominantly on single models with simple ensemble mechanisms and lack an early filtering layer, resulting in limited generalization and high computational burden. A hybrid architecture is proposed, integrating Rule-Based Filtering as an initial screening layer, a Stacking Ensemble combining Random Forest and XGBoost with Logistic Regression as meta-learner, and an explainability module using SHAP and Large Language Model to generate natural language justifications for each prediction. Hyperparameter optimization was performed using a Genetic Algorithm. Controlled evaluation on the test dataset demonstrates that the Stacking Ensemble achieves the best balanced performance in terms of accuracy and discriminative ability, while the hybrid model reduces machine learning computational load with improved latency consistency. Real-world testing on active URLs further confirms system effectiveness across both controlled and operational conditions. The alignment between SHAP-identified dominant features and Rule-Based Filtering indicators validates the methodological coherence of the proposed architecture. These findings demonstrate that the integration of deterministic filtering, adaptive ensemble learning, and explainability layers produces a phishing detection system that is accurate, computationally efficient, and capable of providing transparent and human-readable decision justifications.

Keywords: *phishing detection, stacking ensemble, rule-based filtering, explainable artificial intelligence, large language model*

Abstrak

Serangan *phishing* yang terus meningkat pada sektor keuangan dan perbankan memerlukan sistem deteksi yang tidak hanya akurat, tetapi juga efisien dan dapat diinterpretasikan. Pendekatan yang ada saat ini masih mengandalkan model tunggal dengan mekanisme

penggabungan sederhana dan tidak memiliki lapisan penyaringan awal, sehingga kemampuan generalisasi terbatas dan beban komputasi tinggi. Arsitektur hibrid diusulkan dengan mengintegrasikan Rule-Based Filtering sebagai lapisan penyaringan awal, Stacking Ensemble yang menggabungkan Random Forest dan XGBoost dengan Logistic Regression sebagai meta-learner, serta modul interpretabilitas berbasis SHAP dan Large Language Model untuk menghasilkan justifikasi prediksi dalam bahasa alami. Optimasi hyperparameter dilakukan menggunakan Genetic Algorithm. Evaluasi terkontrol pada data uji menunjukkan bahwa Stacking Ensemble menghasilkan keseimbangan performa terbaik dari sisi akurasi dan kemampuan diskriminatif, sementara model hibrid berhasil mereduksi beban komputasi machine learning dengan konsistensi latensi yang lebih baik. Pengujian operasional pada URL aktif mengonfirmasi efektivitas sistem pada kondisi nyata. Keselarasan antara fitur dominan hasil analisis SHAP dan indikator Rule-Based Filtering memvalidasi koherensi metodologis arsitektur yang diusulkan. Temuan ini menunjukkan bahwa integrasi penyaringan deterministik, ensemble learning adaptif, dan lapisan interpretabilitas menghasilkan sistem deteksi *phishing* yang akurat, efisien secara komputasi, serta mampu menyediakan justifikasi keputusan yang transparan dan dapat dipahami pengguna.

Kata kunci: deteksi phishing, stacking ensemble, pemfilteran berbasis aturan, kecerdasan buatan yang dapat dijelaskan, large language model.

Pendahuluan

Serangan phishing merupakan salah satu ancaman keamanan siber yang paling signifikan, yaitu bentuk kejahatan siber yang memanfaatkan teknik manipulasi untuk mengelabui korban agar mengakses situs web palsu dan menyerahkan informasi sensitif seperti kredensial akun serta data keuangan [1]. Menurut laporan Anti Phishing Group (APWG), tercatat 1.003.924 serangan phishing secara global pada kuartal pertama 2025 angka tertinggi sejak akhir 2023 dengan tren peningkatan bertahap dari 877.536 insiden pada awal 2024 menjadi 989.123 insiden pada akhir tahun yang sama [2]. Sektor layanan keuangan dan perbankan menjadi target utama dengan proporsi 30,9 persen dari seluruh serangan [3]. Urgensi ini mendorong pengembangan sistem deteksi yang akurat, adaptif, dan efisien secara komputasi [4].

Pendekatan machine learning telah banyak digunakan dalam mendeteksi phishing dan menunjukkan kinerja yang baik dalam berbagai penelitian [5]. Beberapa studi terdahulu membandingkan berbagai algoritma klasifikasi, termasuk Gradient Boosting, Random Forest, Decision Tree, SVC, dan K-Neighbors Classifier, dimana hasil dari dua algoritma pertama secara konsisten menunjukkan keunggulan serta performa tertinggi [6]. Studi lain menemukan bahwa Random Forest dan XGBoost mengungguli Support Vector Machine dalam akurasi deteksi phishing [7]. Namun sebagian besar studi tersebut memiliki sejumlah keterbatasan mendasar: model tunggal rentan terhadap bias varians tinggi sehingga generalisasinya terbatas [6] [8],


mekanisme penggabungan model masih sederhana seperti rata-rata probabilitas tanpa memanfaatkan meta-learning adaptif [9], serta tidak tersedia lapisan penyaringan awal berbasis aturan yang mampu mereduksi beban komputasi machine learning, dan meminimalisasi kesalahan deteksi pada tahap awal pipeline [10].

Meskipun peningkatan kinerja klasifikasi telah menjadi fokus utama berbagai studi, kemampuan interpretasi model juga menjadi perhatian penting dalam pengembangan sistem deteksi phishing [11]. Model ensemble seperti Random Forest dan XGBoost umumnya menghasilkan prediksi yang sulit diinterpretasikan karena proses pengambilan keputusannya tidak dapat diamati secara langsung [12]. Metode Explainable Artificial Intelligence (XAI) seperti SHapley Additive exPlanations (SHAP) telah banyak digunakan untuk menjelaskan kontribusi fitur terhadap hasil prediksi [13], namun hasil interpretasi yang dihasilkan masih didominasi oleh representasi numerik dan visualisasi teknis yang kurang mudah dipahami oleh pengguna nonteknis [14][15]. Berdasarkan kondisi tersebut, masih terdapat celah penelitian berupa belum tersedianya arsitektur deteksi phishing yang mengintegrasikan mekanisme penyaringan berbasis aturan, teknik ensemble learning yang memanfaatkan keunggulan beberapa algoritma secara bersamaan, serta mekanisme interpretabilitas yang mampu menerjemahkan hasil prediksi ke dalam penjelasan berbahasa alami dalam satu kerangka sistem yang terpadu.

Arsitektur deteksi phishing hibrid yang diusulkan mengintegrasikan tiga komponen yang saling melengkapi : pertama *Rule- Based Filtering* sebagai lapisan awal menggunakan aturan deterministik berbasis indikator phishing tervalidasi; kedua *Stacking Ensemble* yang menggabungkan Random Forest sebagai algoritma bagging dan XGBoost sebagai algoritma boosting dengan memanfaatkan Logistic Regression sebagai meta-learner; ketiga modul *Explainable AI* menggunakan SHAP untuk menjelaskan masing-masing kontribusi fitur dalam menghasilkan prediksi yang diperkuat oleh *Large Language Model* (LLM) untuk menghasilkan reasoning tekstual otomatis. Optimasi hyperparameter dilakukan menggunakan Genetic Algorithm untuk mengeksplorasi ruang pencarian yang lebih luas dibandingkan grid search konvensional. Kontribusi utama yang dihasilkan mencakup rancangan arsitektur deteksi phishing hibrid yang memadukan *Rule-Based Filtering* sebagai lapisan penyaringan awal, *Stacking Ensemble* sebagai inti klasifikasi, dan modul SHAP LLM sebagai lapisan interpretabilitas yang menerjemahkan keputusan model ke dalam penjelasan berbahasa alami. Penelitian ini juga menyajikan analisis kuantitatif atas trade-off kinerja antara akurasi, recall, efisiensi komputasi, dan interpretabilitas berdasarkan evaluasi pada dataset dan skenario pengujian operasional.

Metode Penelitian

Pendekatan eksperimen berbasis machine learning digunakan untuk mendeteksi URL phishing melalui integrasi Rule-Based Filtering dan Stacking Ensemble, yang arsitekturnya ditunjukkan pada Gambar 1. Alur kerja sistem dimulai ketika URL diterima sebagai masukan dan diekstraksi fitur-fiturnya, kemudian memasuki tahap penyaringan awal menggunakan Rule-Based Filtering; URL yang tidak dapat diklasifikasikan secara langsung diteruskan ke model Stacking Ensemble yang terdiri dari Random Forest dan XGBoost sebagai base learner dengan Logistic Regression sebagai meta-learner. Hasil prediksi selanjutnya dianalisis menggunakan SHAP untuk menghasilkan nilai kontribusi fitur yang diterjemahkan oleh Large Language Model (LLM) menjadi penjelasan berbahasa alami. Kontribusi setiap komponen dievaluasi melalui empat skenario eksperimen: Random Forest mandiri, XGBoost mandiri, Stacking Ensemble tanpa Rule-Based Filtering, dan sistem hibrid yang menggabungkan keduanya.



Gambar 1 Arsitektur Penelitian

Dataset yang digunakan adalah *dataset_phishing* yang bersumber dari repositori publik Kaggle, terdiri dari 11.430 sampel dengan 89 fitur dan distribusi kelas yang seimbang antara kelas phishing dan legitimate. Enam fitur dieliminasi berdasarkan zero variance dan irelasi terhadap skenario deteksi URL, satu data duplikat dihapus, sehingga tersisa 83 fitur aktif dari 11.429 sampel bersih yang dibagi dengan rasio 80:20 untuk pelatihan dan pengujian. Ekstraksi fitur bersifat adaptif: ketika halaman web berhasil diakses, diekstraksi 81 fitur hibrida yang mencakup fitur struktural URL, konten halaman, serta informasi domain; apabila tidak dapat diakses, sistem beralih ke mode fallback dengan 37 fitur berbasis struktur URL saja. Kedua set

fitur merupakan subset dari 83 fitur dataset utama sehingga kompatibel langsung dengan model yang telah dilatih.

Lapisan pertama pipeline adalah Rule-Based Filtering yang berfungsi sebagai penyaringan deterministik untuk mengidentifikasi URL mencurigakan sebelum analisis machine learning dilakukan. Dari 83 fitur yang tersedia, 24 fitur dipilih sebagai dasar pembentukan aturan berdasarkan kemampuan merepresentasikan karakteristik phishing secara eksplisit, konsistensi kemunculannya pada URL phishing, serta kemudahan formulasi menjadi aturan deterministik; fitur yang bersifat statistik atau memerlukan pembelajaran hubungan non-linear tetap dimanfaatkan pada tahap machine learning. Keseluruhan 24 aturan beserta kategori dan deskripsinya disajikan pada Tabel 1.

Table 1 Aturan Rule-Based Filtering

No	Rule	Kategori	Deskripsi
1.	suspicious_tld	Sangat Penting	TLD yang ditandai sebagai mencurigakan. TLD Negara, TLD Generik Baru (New gTLD), dan TLD dengan Reputasi Buruk.
2.	random_domain	Sangat Penting	Domain acak atau tidak bermakna menunjukkan pembuatan domain secara otomatis untuk aktivitas phishing.
3.	ip	Sangat Penting	Hostname yang menggunakan alamat IP alih-alih nama domain dianggap sebagai indikator phishing.
4.	shortening_service	Sangat Penting	Jika URL menggunakan layanan pemendek (bit.ly, tinyurl), ditandai mencurigakan.
5.	http_in_path	Sangat Penting	Jika kata http muncul pada <i>path</i> , menandakan upaya penyamaran URL
6.	nb_subdomains	Penting	> 3 subdomain ditandai sebagai mencurigakan
7.	nb_dots	Penting	> 4 karakter titik (.) ditandai sebagai mencurigakan
8.	nb_slash	Penting	> 7 karakter garis miring (/) ditandai sebagai mencurigakan
9.	length_hostname	Penting	> 30 panjang karakter hostname ditandai sebagai mencurigakan
10.	nb_at	Penting	≥ 1 karakter "@" ditandai sebagai mencurigakan, jika "@" sebelum <i>hostname</i> ditandai sebagai <i>phishing</i>
11.	nb_percent	Penting	> 5 karakter persen (%) ditandai sebagai mencurigakan
12.	nb_tilde	Penting	≥ 1 karakter tilde "~" ditandai sebagai mencurigakan
13.	nb_semicolumn	Penting	≥ 1 karakter titik koma (;) ditandai sebagai mencurigakan
14.	nb_star	Penting	≥ 1 karakter <i>star</i> (*) ditandai sebagai mencurigakan
15.	nb_comma	Penting	≥ 1 karakter koma (,) ditandai sebagai mencurigakan
16.	nb_dollar	Penting	≥ 1 karakter dolar "\$" ditandai sebagai mencurigakan
17.	nb_qm	Penting	> 2 karakter tanda tanya "?" ditandai sebagai mencurigakan

No	Rule	Kategori	Deskripsi
18.	nb_colon	Penting	> 1 karakter titik dua (:) (lebih dari protokol)
19.	nb_eq	Penting	> 8 karakter sama dengan (=) ditandai sebagai mencurigakan
20.	nb_and	Penting	> 3 karakter and "&" ditandai sebagai mencurigakan
21.	nb_hyphens	Penting	> 3 karakter minus (-) ditandai sebagai mencurigakan
22.	nb_underscore	Penting	> 3 karakter garis bawah (_) ditandai sebagai mencurigakan, jika pada domain ditandai sebagai sangat mencurigakan
23.	ratio_digits_url	Cukup Penting	Persentase angka dalam <i>hostname</i> . Jika > 0.3 (lebih dari 30% URL adalah angka)
24.	port	Cukup Penting	Penggunaan port selain <i>default</i> (Standard Ports: 21, 22, 23, 80, 443, 445, 1433, 1521, 3306, and 3389). ditandai mencurigakan

Aturan-aturan pada Tabel 1 dikelompokkan menjadi tiga kategori berdasarkan tingkat kontribusinya terhadap risiko phishing: kategori sangat penting mencakup empat fitur dengan keterkaitan kuat terhadap indikasi phishing yang jarang ditemukan pada URL sah; kategori penting mencakup 17 fitur yang umum pada situs phishing namun memerlukan kombinasi antar fitur untuk meningkatkan keyakinan klasifikasi; dan kategori cukup penting mencakup dua fitur pendukung untuk melengkapi penilaian risiko secara keseluruhan. Mekanisme pengambilan keputusan berlangsung dalam dua tahap: *High-Confidence Rule* yang langsung mengklasifikasikan URL sebagai phishing apabila terdeteksi minimal satu fitur berkategori sangat penting, dan *Threshold-Based Rule* yang diterapkan apabila tidak ditemukan indikator tersebut, dengan skor risiko dihitung berdasarkan bobot dua untuk fitur kategori penting dan bobot satu untuk kategori cukup penting.

Berdasarkan skor risiko tersebut, URL diklasifikasikan ke dalam tiga kategori sebagaimana ditunjukkan pada Tabel 2. URL dengan skor lebih dari atau sama dengan lima diklasifikasikan langsung sebagai phishing, sementara skor satu hingga empat dikategorikan sebagai suspicious dan skor nol sebagai benign; kedua kategori terakhir diteruskan ke tahap machine learning karena indikatornya belum cukup konklusif untuk menghasilkan keputusan deterministik.

Table 2 Nilai skor Risiko Rule-Based Filtering

<i>Risk Score</i>	Kategori
≥ 5	<i>Phishing</i>
1-4	<i>Suspicious</i>
0	<i>Benign</i>

Pada tahap machine learning, Random Forest dan XGBoost digunakan sebagai base learner karena karakteristiknya yang saling melengkapi: Random Forest

mereduksi varians melalui mekanisme bagging, sedangkan XGBoost mereduksi bias secara adaptif melalui gradient boosting yang diperkuat regularisasi L1 (reg_alpha) dan L2 (reg_lambda) untuk mengendalikan overfitting. Optimasi hyperparameter kedua model dilakukan menggunakan Genetic Algorithm (GA) dengan F1-Score sebagai fungsi fitness, dengan ruang pencarian mencakup n_estimators, max_depth, dan max_features untuk Random Forest, serta learning_rate, max_depth, subsample, dan colsample_bytree untuk XGBoost; konfigurasi optimal hasil GA kemudian digunakan dalam arsitektur Stacking Ensemble dengan Logistic Regression sebagai meta-learner yang menerima keluaran predict_proba dari kedua base learner.

SHAP diterapkan pada dua tingkat: secara global menggunakan summary plot dan bar plot mean absolute SHAP value, serta secara lokal menggunakan force plot untuk prediksi URL individual; TreeExplainer digunakan pada Random Forest dan XGBoost, sedangkan KernelExplainer pada Logistic Regression. Nilai kontribusi SHAP selanjutnya diteruskan ke LLM bersama label prediksi dan nilai probabilitas untuk menghasilkan narasi penjelasan berbahasa alami. Evaluasi dilakukan dalam dua tahap: evaluasi terkontrol pada data uji menggunakan metrik accuracy, precision, recall, F1-Score, dan AUC disertai confusion matrix, serta evaluasi operasional menggunakan 40 URL aktif terdiri dari 20 URL benign dan 20 URL phishing untuk mengukur kesenjangan performa antara kondisi terkontrol dan kondisi nyata. Keempat skenario eksperimen dievaluasi pada kedua tahap untuk memungkinkan perbandingan yang sistematis terhadap kontribusi masing-masing komponen arsitektur.

Hasil dan Pembahasan

1. Hasil Evaluasi Performa Model

Pengujian dilakukan terhadap delapan varian model yang dikelompokkan berdasarkan dua mode ekstraksi fitur: mode 37 fitur berbasis struktur URL sebagai fallback saat halaman tidak dapat diakses, dan mode 81 fitur hibrid yang menggabungkan fitur URL, konten halaman, serta informasi domain. Optimasi hyperparameter menggunakan Genetic Algorithm menghasilkan konfigurasi yang berbeda secara signifikan antara Random Forest dan XGBoost, sebagaimana ditunjukkan pada Tabel 3 dan Tabel 4.


Table 3 Hyperparameter Random Forest


Hyperparameter	Nilai
n_estimators	464
max_depth	14
min_samples_split	4
min_samples_leaf	1
max_features	log2
random_state	12

Table 4 Hyperparameter XGBoost

Hyperparameter	Nilai
n_estimators	372
learning_rate	0,1266
max_depth	5
subsample	0,7610
colsample_bytree	0,7113
min_child_weight	3,8671
gamma	0,4511
reg_alpha	0,6643
reg_lambda	2,2702
random_state	12

Perbandingan performa seluruh model berdasarkan metrik accuracy, precision, recall, F1-score, dan AUC disajikan pada Gambar 2 dan Gambar 3.

**Gambar 2 Evaluasi Metrik Model 37 Fitur**



Gambar 3 Evaluasi Metrik Model 81 Fitur

Perbedaan yang paling mencolok adalah selisih konsisten enam hingga tujuh poin persentase antara kelompok model 81 fitur dan kelompok model 37 fitur pada seluruh metrik evaluasi, mengonfirmasi bahwa fitur konten halaman web memberikan kontribusi diskriminatif yang signifikan dalam membedakan situs phishing dari situs sah yang menyerupainya secara struktural URL. Pada kelompok model 81 fitur, Random Forest menghasilkan precision tertinggi (98,3 persen) namun recall lebih rendah (94,8 persen), mencerminkan karakteristik bagging yang konservatif dalam melabeli URL sebagai phishing. XGBoost mencatatkan performa terbaik secara keseluruhan dengan accuracy 97,64 persen, F1-Score 97,63 persen, dan AUC 99,69 persen, dengan distribusi kesalahan yang lebih seimbang ($FP = 25$, $FN = 29$); keunggulan ini menunjukkan bahwa mekanisme boosting yang memperbaiki residual secara iteratif lebih efektif menangani kompleksitas pola phishing dibandingkan agregasi independen pada bagging.

Stacking Ensemble menghasilkan performa sebanding dengan XGBoost (accuracy 97,51 persen, AUC 99,63 persen) dengan keseimbangan FP dan FN yang lebih baik ($FP = 26$, $FN = 30$), dan meskipun tidak melampaui XGBoost sebagai model tunggal fenomena yang umum terjadi ketika salah satu base learner telah mencapai performa sangat tinggi Stacking Ensemble tetap lebih sesuai untuk sistem yang memprioritaskan minimisasi false negative dalam konteks deteksi ancaman. Perbandingan distribusi kesalahan klasifikasi seluruh model disajikan pada Tabel 5 dan Tabel 6. Angka $FP = 25$ dan $FN = 29$ pada XGBoost mode 81 fitur mencerminkan distribusi kesalahan yang paling seimbang di antara seluruh model, konsisten dengan

karakteristik gradient boosting yang menghasilkan batas keputusan lebih presisi dibandingkan bagging.

Table 5 Confusion Matrix Gabungan Model 81 Fitur

Model	TN	FP	FN	TP
Random Forest	1.124	19	60	1.083
XGBoost	1.118	25	29	1.114
Stacking	1.117	26	30	1.112
Hybrid	1.065	78	30	1.113

Table 6 Confusion Matrix Gabungan Model 37 Fitur

Model	TN	FP	FN	TP
Random Forest	1.048	95	152	991
XGBoost	1.055	88	149	994
Stacking	1.044	99	128	1.015
Hybrid	1.002	141	125	1.018

Penerapan Rule-Based Filtering pada arsitektur Hybrid memberikan dampak ganda yang perlu dianalisis secara cermat. Dari total 2.286 URL data uji, sebanyak 560 URL (24,5 persen) berhasil disaring langsung tanpa melibatkan komputasi machine learning. Model Hybrid menghasilkan recall tertinggi sebesar 97,81 persen, namun disertai penurunan precision menjadi 88,52 persen akibat peningkatan FP menjadi 145 hampir lima kali lipat dibandingkan Stacking. Fenomena ini bersumber dari sifat deterministik aturan heuristik yang tidak dapat membedakan URL benign dengan karakteristik teknis mencurigakan dari URL phishing sesungguhnya, dan keputusan pada lapisan rule-based tidak dapat dikoreksi oleh Stacking Ensemble. Dalam konteks prinsip defense-in-depth pada keamanan siber, trade-off ini dapat diterima karena gagal mendeteksi phishing (*false negative*) umumnya jauh lebih merugikan daripada peringatan berlebih (*false positive*).

2. Hasil Efisiensi dan Konsistensi Komputasi

Dari perspektif efisiensi komputasi, Rule-Based Filtering menghasilkan reduksi beban machine learning sebesar 24,5 persen, peningkatan throughput dari 7.542 menjadi 7.750 URL per detik, dan penghematan batch time dari 0,303 detik menjadi 0,295 detik sebagaimana ditunjukkan pada Tabel 7. Meskipun peningkatan 2,7 persen terlihat moderat pada skala eksperimen ini, dampaknya akan semakin signifikan pada sistem produksi berskala besar karena penyaringan awal mereduksi beban kumulatif secara proporsional terhadap volume data. Lebih relevan secara operasional, model Hybrid menunjukkan standar deviasi latency lebih rendah (4,577 ms) dibandingkan Stacking (6,985 ms), mengindikasikan konsistensi prediksi yang lebih baik. Dalam sistem deteksi keamanan siber real-time, konsistensi waktu respons sering kali lebih

bernilai dari sekadar kecepatan rata-rata karena lonjakan latency yang tidak terduga dapat mengganggu stabilitas sistem.

Table 7 Perbandingan Efisiensi Pemrosesan Model


Aspek	Stacking	Hybrid	Analisis
Total URL	2.286	2.286	Sama
URL diproses Rule-Based	0 (0%)	560 (24,5%)	Hybrid mengurangi beban ML
URL diproses ML	2.286 (100%)	1.726 (75,5%)	Reduksi beban komputasi
Batch Time (detik)	0.1972	0.1736	Lebih cepat 12.0%
Throughput (URL/detik)	11.593,1	13.164,7	Hybrid sedikit lebih tinggi

Table 8 Latency Prediksi per URL

Model	Latency (ms)	Min (ms)	Max (ms)	Std (ms)
Random Forest	117.247	72.672	159.430	23.000
XGBoost	12.426	9.623	22.808	3.166
<i>Stacking ensemble</i>	134.313	113.274	241.678	31.367
Hybrid	119.318	102.043	137.765	10.880

3. Hasil Interpretabilitas Model

Analisis SHAP pada Gambar 4 menunjukkan bahwa fitur reputasi domain dan karakteristik halaman web memiliki kontribusi terbesar pada kedua model: *google_index* dan *page_rank* mendominasi Random Forest, sementara *page_rank* dan *google_index* juga menempati peringkat teratas pada XGBoost diikuti *nb_www*, *nb_hyperlinks*, dan *phish_hints*. Konsistensi pola ini mengonfirmasi bahwa fitur non-URL seperti *page_rank*, *google_index*, *web_traffic*, dan *nb_hyperlinks* lebih diskriminatif dibandingkan karakteristik struktur URL saja, sekaligus menjelaskan mengapa model 81 fitur secara konsisten mengungguli model 37 fitur pada seluruh metrik evaluasi.



Gambar 4 Top Fitur Kontribusi SHAP

Analisis SHAP menunjukkan bahwa beberapa fitur yang digunakan dalam Rule-Based Filtering, seperti *phish_hints*, *nb_hyphens*, *length_hostname*, dan *https_token*, juga termasuk dalam kelompok fitur yang berkontribusi terhadap proses klasifikasi. Temuan ini menunjukkan adanya keselarasan antara indikator berbasis pengetahuan domain yang digunakan pada tahap penyaringan awal dan pola yang

dipelajari oleh model machine learning. Dengan demikian, Rule-Based Filtering tidak hanya berperan sebagai mekanisme penyaringan awal, tetapi juga memanfaatkan karakteristik yang terbukti relevan berdasarkan hasil interpretasi model.

Table 9 Fitur Dominan SHAP

Fitur	SHAP RF	SHAP XGB	SHAP STACKING	Status Rule
page_rank	0.0749	1.5294	0.1092	X Belum
google_index	0.0888	1.1084	0.0945	X Belum
nb_www	0.0358	0.9198	0.0472	X Belum
nb_hyperlinks	0.0418	0.7248	0.0453	X Belum
phish_hints	0.0195	0.5188	0.0242	X Belum
domain_age	0.0220	0.4267	0.0218	X Belum
web_traffic	0.0391	0.3631	0.0287	X Belum

Berdasarkan tabel diatas menunjukkan tujuh fitur yang secara konsisten masuk ke dalam sepuluh besar di ketiga model sekaligus. Ketujuh fitur tersebut *page_rank*, *google_index*, *nb_www*, *nb_hyperlinks*, *phish_hints*, *domain_age*, dan *web_traffic* seluruhnya belum tercakup dalam 24 aturan pada lapisan Rule-Based Filtering yang ada saat ini. Temuan ini membuka peluang konkret untuk memperkuat lapisan Rule-Based Filtering: fitur seperti *phish_hints* dapat diformulasikan sebagai aturan berbasis deteksi kata kunci phishing pada struktur URL, sementara *domain_age* dapat dijadikan aturan ambang batas usia domain minimum sebagai indikator kecurigaan. Integrasi fitur-fitur ini ke dalam lapisan Rule-Based Filtering berpotensi meningkatkan cakupan penyaringan deterministik, sehingga lebih banyak URL phishing dapat disaring sejak tahap awal tanpa bergantung sepenuhnya pada komputasi machine learning.

4. Hasil analisis Komponen LLM

Komponen LLM menerjemahkan nilai kontribusi SHAP yang bersifat numerik menjadi narasi penjelasan berbahasa alami. Pada URL legitimate (<https://www.ietf.org/>) model menghasilkan probabilitas phishing 0,3597 dengan kontribusi ke arah benign (-0,4717) yang lebih dominan dari kontribusi ke arah phishing (+0,3323), LLM menerjemahkan hasil menjadi penjelasan bahwa URL dinyatakan aman berdasarkan reputasi domain tinggi dan struktur halaman yang konsisten dengan situs sah. Pada URL phishing (<http://nmhokdypni.sum4iit.club/vnafvra97w/?q=3717065149&id=100>) model menghasilkan probabilitas 0,7405 yang didominasi ratio_digits_url (+0,2324) dan nb_www (+0,0974), dan LLM mengidentifikasi rasio digit URL yang tinggi serta penggunaan subdomain tidak standar sebagai faktor penentu. Kesesuaian antara hasil SHAP dan reasoning LLM membuktikan bahwa sistem tidak hanya mampu melakukan klasifikasi akurat, tetapi juga menyediakan justifikasi yang transparan dan dapat dipahami pengguna nonteknis untuk setiap keputusan prediksi. Keluaran reasoning LLM untuk URL sampel disajikan pada Tabel berikut.

Table 10 Hasil Keluaran LLM pada sampel URL

AI Reasoning


Hasil deteksi sistem menunjukkan bahwa URL yang diperiksa memiliki probabilitas phishing yang sangat tinggi, yaitu 0.95, yang mana jauh melebihi ambang batas bahaya yang ditentukan (≥ 0.6). Hal ini menunjukkan bahwa URL tersebut sangat mungkin digunakan sebagai sarana penipuan, dan model yang digunakan untuk menganalisisnya telah mendeteksi pola-pola mencurigakan yang umum ditemukan dalam phishing. Dengan demikian, terdapat dukungan kuat untuk kesimpulan akhir bahwa URL ini berbahaya. REKOMENDASI: BLOKIR.

5. Hasil Evaluasi Eksperimen

Evaluasi operasional dilakukan menggunakan 40 URL aktif yang dikumpulkan secara manual, terdiri atas 20 URL legitimate dan 20 URL phishing. Sebagian besar URL phishing tidak dapat diakses saat pengujian sehingga sistem beroperasi menggunakan mode fallback 37 fitur, kondisi yang berkontribusi terhadap kesenjangan kinerja antara pengujian operasional dan evaluasi terkontrol. Perbandingan performa keempat model disajikan pada Tabel 11 dan Gambar 5.

Table 11 Confusion Matrix Eksperimen

Model	TN	FP	FN	TP
Random Forest	17	3	2	18
XGBoost	20	1	5	15
Stacking	18	2	2	18
Hybrid	17	3	3	18



Gambar 5 Evaluation Metrik Eksperimen

Stacking Ensemble mencapai kinerja terbaik dengan accuracy 90,0 persen dan distribusi kesalahan paling seimbang (FP = dua, FN = dua), membuktikan bahwa meta-

learner berhasil mengompensasi kelemahan masing-masing base learner. Random Forest dan Hybrid menunjukkan recall tinggi (90,0 persen) namun dengan tiga false positive, sementara XGBoost hanya menghasilkan satu false positive tetapi melewati lima URL phishing akibat karakteristiknya yang lebih konservatif. Dalam konteks keamanan siber, melewati URL phishing jauh lebih berbahaya daripada salah menandai situs aman, sehingga Stacking yang menyeimbangkan keduanya lebih sesuai untuk skenario operasional. Secara khusus, Rule-Based Filtering pada model Hybrid berhasil mengidentifikasi tiga URL phishing langsung dari lapisan aturan tanpa komputasi machine learning, membuktikan kontribusi nyata komponen deterministik ini. Kesenjangan performa terhadap evaluasi terkontrol pada seluruh model terutama disebabkan oleh ketergantungan mode fallback 37 fitur, yang mengindikasikan perlunya strategi pengayaan fitur untuk URL tidak responsif pada pengembangan berikutnya.

Secara keseluruhan, hasil pengujian menunjukkan bahwa pendekatan *hybrid* yang mengintegrasikan Rule-Based Filtering dengan Stacking Ensemble mampu mengurangi beban komputasi melalui penyaringan awal terhadap URL yang dapat diklasifikasikan secara deterministik, sekaligus mempertahankan kinerja deteksi yang tinggi dengan menekan jumlah *false negative*. Dengan demikian, sistem tidak hanya lebih efisien dalam penggunaan sumber daya komputasi, tetapi juga lebih andal dalam mendeteksi URL phishing, sehingga lebih sesuai untuk diterapkan pada lingkungan operasional.

Simpulan

Penelitian ini dilakukan untuk menjawab tiga pertanyaan penelitian yang dirumuskan berdasarkan empat keterbatasan pada studi terdahulu dalam bidang deteksi *phishing*: dominasi arsitektur model tunggal yang rentan terhadap keterbatasan bias-varians, mekanisme penggabungan model yang belum adaptif, ketiadaan lapisan penyaringan awal yang efisien secara komputasi, dan rendahnya interpretabilitas model *black-box* yang menyulitkan pemahaman keputusan prediksi oleh pengguna nonteknis. Penelitian ini mengusulkan pendekatan hybrid yang mengombinasikan *Rule-Based Filtering* dan *Stacking Ensemble* yang dioptimalkan melalui Genetic Algorithm untuk meningkatkan deteksi phishing. Selain aspek performa, penelitian ini juga mengintegrasikan SHAP dan LLM guna menghasilkan penjelasan prediksi yang lebih informatif dan mudah dipahami.

Hasil evaluasi terhadap 2.286 URL pada data uji menunjukkan bahwa arsitektur ensemble mampu menghasilkan performa yang lebih stabil dibandingkan model tunggal. Stacking Ensemble menghasilkan keseimbangan sensitivitas dan spesifisitas terbaik dengan *accuracy* 97,51%, *recall* 97,29%, dan AUC 0,9963, membuktikan bahwa pendekatan *meta-learning* adaptif mampu mengatasi keterbatasan bias-varians yang menjadi kelemahan inheren model tunggal. XGBoost mencapai performa

tertinggi secara individual dengan *accuracy* 97,64%, *precision* 97,81%, *recall* 97,46%, *F1-score* 97,63%, dan AUC 0,9969 keunggulan yang tidak terlepas dari efektivitas optimasi Genetic Algorithm dalam mengeksplorasi ruang *hyperparameter* XGBoost yang lebih kompleks dibandingkan Random Forest. Random Forest menghasilkan *precision* tertinggi sebesar 98,28% namun dengan *recall* 94,75%, menunjukkan karakteristik klasifikasi yang lebih konservatif dengan risiko *false negative* yang lebih tinggi dibandingkan model lainnya.

Penerapan Rule-Based Filtering sebagai lapisan penyaringan awal terbukti memberikan dampak ganda terhadap efisiensi dan konsistensi kinerja sistem. Rule-Based Filtering berhasil menyaring 24,5% URL (560 dari 2.286) secara langsung tanpa melibatkan komputasi model *machine learning*, sehingga mengurangi beban pemrosesan pada lapisan Stacking Ensemble secara signifikan. Pada pengujian operasional terhadap 40 URL aktif, 15 URL *phishing* berhasil diidentifikasi langsung oleh mekanisme aturan heuristik. Integrasi Rule-Based Filtering meningkatkan *recall* sistem menjadi 97,81% pada Hybrid dengan hanya 25 *false negative*, namun disertai konsekuensi peningkatan *false positive* yang signifikan (FP = 145) akibat sifat deterministik aturan heuristik yang tidak dapat dikoreksi secara adaptif oleh lapisan *machine learning* suatu *trade-off* yang menjadi temuan kritis arsitektur yang diusulkan.

Integrasi SHAP dan LLM terbukti menghasilkan justifikasi prediksi yang transparan dan dapat dipahami pengguna nonteknis. Konsistensi yang ditemukan antara fitur dominan pada analisis SHAP dan indikator pada Rule-Based Filtering sekaligus memperkuat validitas metodologis arsitektur secara keseluruhan. Meskipun demikian, peran LLM dalam penelitian ini masih terbatas sebagai penjelas pasca-klasifikasi berdasarkan output SHAP, bukan sebagai komponen aktif dalam proses deteksi.

Berdasarkan keseluruhan temuan dan keterbatasan yang teridentifikasi, terdapat tiga arah pengembangan yang secara langsung berakar pada masalah penelitian, pilihan metode, serta hasil analisis yang diperoleh. Pertama, kesenjangan kinerja antara evaluasi pada *dataset* pengujian dan lingkungan operasional yang disebabkan oleh ketergantungan pada model 37 fitur ketika halaman URL tidak dapat diakses mengindikasikan perlunya integrasi sumber reputasi domain eksternal seperti PhishTank dan OpenPhish sebagai lapisan informasi tambahan untuk URL yang tidak responsif. Kedua, *trade-off precision* pada model Hybrid yang bersumber dari sifat deterministik Rule-Based Filtering mengindikasikan perlunya mekanisme pembaruan aturan secara dinamis berbasis prediksi model, agar sistem dapat mengikuti evolusi pola serangan yang terus berkembang. Ketiga, peran LLM yang masih terbatas pada fungsi eksplanasi pasca-klasifikasi membuka ruang pengembangan menuju

pemanfaatan LLM sebagai agen *real-time threat intelligence retrieval* yang aktif, berpotensi meningkatkan kemampuan deteksi terhadap serangan *phishing* baru yang belum terwakili dalam data latih.

Daftar Pustaka

- [1] L. Aziz, F. Ardy, I. Istiqomah, A. E. Ezer, S. N. Neyman, and K. Linux, "Phishing di Era Media Sosial : Identifikasi dan Pencegahan Ancaman di Platform Sosial," no. 4, pp. 1–11, 2024.
- [2] G. Response and T. Cybercrime, "4 Quarter," no. February, 2026.
- [3] E. Mouncey and S. Ciobotaru, "on impact and effectiveness," *J. Econ. Criminol.*, vol. 7, no. December 2024, p. 100125, 2025, doi: 10.1016/j.jeconc.2025.100125.
- [4] F. P. E. Putra, U. Ubaidi, A. Zulfikri, G. Arifin, and R. M. Ilhamsyah, "Analysis of Phishing Attack Trends, Impacts and Prevention Methods: Literature Study," *Brill. Res. Artif. Intell.*, vol. 4, no. 1, pp. 413–421, 2024, doi: 10.47709/brilliance.v4i1.4357.
- [5] R. Zieni, L. Massari, and M. C. Calzarossa, "Phishing or Not Phishing? A Survey on the Detection of Phishing Websites," *IEEE Access*, vol. 11, no. January, pp. 18499–18519, 2023, doi: 10.1109/ACCESS.2023.3247135.
- [6] A. Khan, D. M. Ahmed, and A. Fathima, "Enhanced Phishing Detection Using Machine Learning Algorithms: A Comparative Study of Random Forest, SVM, and Logistic Regression Models," *SSRN Electron. J.*, 2025, doi: 10.2139/ssrn.5191566.
- [7] V. A. Onih, "Phishing Detection Using Machine Learning : A Model Development and Integration," vol. 07, no. 04, pp. 27–63, 2024.
- [8] "08-Article_Phishing Website Detection With Semantic Features Based on Machine Learning Classifiers A Comparative Study.pdf."
- [9] A. Fajar, S. Yazid, and I. Budi, "Enhancing Phishing Detection through Feature Importance Analysis and Explainable AI : A Comparative Study of CatBoost , XGBoost , and EBM Models".
- [10] A. B. Nassif, M. A. Talib, Q. Nasir, and F. M. Dakalbab, "Machine Learning for Anomaly Detection: A Systematic Review," *IEEE Access*, vol. 9, pp. 78658–78700, 2021, doi: 10.1109/ACCESS.2021.3083060.
- [11] Y. Nohara, K. Matsumoto, H. Soejima, and N. Nakashima, "Explanation of Machine Learning Models Using Shapley Additive Explanation and," vol. 214, no. February, pp. 1–7, 2022.
- [12] S. S. Shafin, "An explainable feature selection framework for web phishing detection with machine learning," *Data Sci. Manag.*, vol. 8, no. 2, pp. 127–136, 2025, doi: 10.1016/j.dsm.2024.08.004.

-
- [13] M. Perceptron, D. Gaspar, P. Silva, and C. Silva, “Explainable AI for Intrusion Detection Systems : LIME and SHAP Applicability,” *IEEE Access*, vol. PP, no. Ml, p. 1, 2024, doi: 10.1109/ACCESS.2024.3368377.
 - [14] M. Li, H. Sun, Y. Huang, and H. Chen, “Shapley value : from cooperative game to explainable artificial intelligence,” vol. 8, 2024, doi: 10.1007/s43684-023-00060-8.
 - [15] L. Hu and K. Wang, “Computing SHAP Efficiently Using Model Structure Information 1,” pp. 1–15.